

Avocado Case

Datavalidering

Row:

Kun 52 rækker, men der er over 18.000 linjer data. Dvs de afhænger af noget andet. Check.

Date:

Der er data fra fire år: 2015, 2016, 2017 og 2018, men for 2018 er der kun data for de første 3 måneder af året. Data fra 2018 vil blive fravalgt på f.eks. sammenligninger mellem år, da totalerne vil adskille sig pga datamangel.

Der er ikke data fra alle datoer, kun 4-5 gange om måneden, altid med 7 dage imellem. Det ser ud som om dato tilknyttedes en registreringsdag, og der kun registreres een gang om ugen. Om det drejer sig om at butikkerne rapporterer alle ugens solgte varer den dag, eller om de rapporterer dagligt men informationen forsvinder fordi et centralt register kun tildeler dato når det registrerer, er ukendt.

AveragePrice:

Denne svinger mellem 0.44 og 3.25. Det er store forskelle. Check.

Total Volume:

Denne svinger også meget, fra 381 til 61 millioner.

Måske et spørgsmål om at totalen fra de første 3 måneder af 2018 er meget lille. Det kunne man undersøge.

Avocado 'antal':

Fælles for 4042, 4225 og 4770, Total Bags er at de angives som 'antal' men ikke i heltal. F.eks. 842.4. De sælger i 10nde-dele..

Det antages at de opgør antallet som 'solgte gram af størrelse X avocado og dividerer med gennemsnitsvægten af den størrelse for at få 'antallet'.

Dette kan i så fald få 'antallet' til at svinge; hvis der sælges mange i den lavere ende af skalaen, vil de blive beregnet som færre, og omvendt vil store avocadoer blive beregnet som flere.

Hvad er en del af hvad?

Total.Volume synes at være summen af 4042, 4225, 4770 og Total Bags.

Total Bags synes at udgøres af Small Bags, Large Bags og XLarge Bags.

Dette giver mening for Total Bags, men rejser spørgsmålet om hvad Total Volume skal betyde.

Antallet af solgte net synes ikke at give mening sammenblandet med antallet af solgte enkelt-avocadoer.

Det vil give mere mening hvis 'antallet' for Bags' vedkommende også tælles i antal avocadoer, sikkert regnet som solgt vægt divideret med avocado-gennemsnitsvægt.

Men om dét er tilfældet eller ej synes at være et stort sats uden at have undersøgt det nærmere.

4042:

"små/medium: 80-140 gram"

Fra 0 (i alt) til 21 millioner. Angivet som **4225:**

"store: 226-283 gram" - Det ses at avocadoer mellem 141 og 225 gram ikke eksisterer.

Fra 30 (i alt) til 20 millioner. Samme forhold og antagelse som 4042.

4770:

"ekstra store: 226-425 gram" - Dvs 'normalt store' kan også sælges som 'ekstra store' da de passer ind i skalaen.

Fra i alt 0 og op til omk 2 millioner. Samme forhold og antagelse som 4042.

Total Bags:

0-16 millioner. Check.

Small, Large & XLarge Bags:

Fra 0 til 12, 4 og $\frac{1}{2}$ millioner, respektivt. Check.

Type:

'conventional' eller 'organic'. Ingen tomme felter. Godt.

Year:

Fra 2015 til 2018, som man kunne forvente. Check.

Region:

Hmm. Angives som værende amerikanske delstater.

Men er nogle gange en by.

Andre gange en delstat.

Og nogle gange meget specielle angivelser, f.eks. NewOrleansMobile.

Og.. der er også en TotalUS.

Nok en sammenblanding af område-angivelse og salgsmetodikker. Kan overlappe, især delstater vs byer og TotalUS

Jeg tager udgangspunkt i totalUS eller delstater medmindre noget specifikt i det enkelte spørgsmål giver mere mening.

1. Udvikling af antal solgte avocadoer per år for hver type af avocado

Plot: Salgsudvikling for avocado-typer

Brugte datakolonner: "Total.Volume", "Year" og "Type", filtreret på Region=TotalUS

Kun 2015-2017 medtaget.

2. Udvikling af andelen af antal solgte avocadoer per år for hver type af avocado

Plot: Udvikling i salgsandele for avocado-typer

Brugte datakolonner: "Total.Volume", "Year" og "Type", filtreret på Region=TotalUS

Kun 2015-2017 medtaget.

3. Forbrug ift månedens dage

Plot: Forbrug ift månedsdag

Brugte datakolonner: "Total.Volume", "Date", "AveragePrice", filtreret på Region=TotalUS og Date=1,2,3,4,...,30,31.

Grafen er savtakket. Det skyldes at der er variation pr år, og årenes registreringsdage ligger forskudt i forhold til hinanden.

Kun 2015-2017 medtaget.

Hvor mange penge bruger folk bruger på avocadoer fordelt på dagene i hver måned?

Der er kun en meget svagt nedadgående tendens; det virker som om forbruget er næsten konstant.

4. Forbrug på hver type af avocadoer i hele datasættet

Plot: Forbrug af hver avocado-type

Brugte datakolonner: "AveragePrice", "Total.Volume", "type", filtreret på Region=TotalUS og Year=2015/2016/2017.

5. Sammenhænge mellem den gennemsnitlige pris og den totale volumen.

Plot: Sammenhænge mellem pris og volumen

Brugte datakolonner: "AveragePrice", "Total.Volume", filtreret på Region=TotalUS og Year=2015/2016/2017.

Der er en gruppering i punktvisningen. Det drejer sig formentlig om conventionals der sælges i store mængder til lav pris, ift organics der sælges i signifikant mindre mængder til højere priser.

Sælges der flere når de er billige?

Ja, mange salg sker ved lav pris.

Der er nogle variationer. Måske sæson-betonede.

6. Udvikling af gennemsnitspris for hver type af avocado

Der ses en stigning i gennemsnitspris for avocadoer af begge typer.

Plot: Udvikling i gennemsnitspris

Brugte datakolonner: "AveragePrice", "Total.Volume", "type" og opdelt på Year; filtreret på Region=TotalUS og Year=2015/2016/2017.

Vægtet gennemsnit er pr type pr år.